



دانشگاه تهران
پردیس دانشکده‌های فنی

مخابرات وایرلس

گزارش مقاله درس

عنوان مقاله: Federated Learning via
Over-the-Air Computation

سید علیرضا جاوید

۸۱۰۱۹۸۳۷۵

استاد

دکتر صباغیان

۲۵ خرداد ۱۴۰۲

فهرست مطالب

فهرست مطالب	
۱	مقدمه
۲	مدلسازی سیستم و فرمول بندی مسئله
۱.۲	یادگیری فدرال در دستگاه ها
۲.۲	محاسبات بی سیم برای تجميع
۳.۲	فرمول بندی مسئله
۳	بهینه سازی تنک و کم رتبه برای یادگیری فدرال توزیع شده در دستگاه
۱.۳	بهینه سازی تنک و کم رتبه
۲.۳	آنالیز مسئله
۴	نمایش DC برای تابع های تنک و کم رتبه
۱.۴	نمایش DC برای تابع تنک
۲.۴	نمایش DC برای قید کم رتبه
۳.۴	نمایش یکپارچه DC
۵	الگوریتم DC برای برنامه DC با تضمین همگرایی
۱.۵	نمایش به صورت اختلاف تابع های قویا محدب
۲.۵	الگوریتم DC برای ماتریس های تنک و کم رتبه
۳.۵	هزینه محاسباتی و همگرایی
۶	نتایج شبیه سازی
۱.۶	تشخیص انجام پذیری
۲.۶	تعداد دستگاه های انتخاب با MSE مورد نظر
۳.۶	عملکرد روش DC برای یادگیری فدرال گسترده
۷	نتیجه گیری

چکیده

نیاز بشر به داشتن ارتباط با تاخیر کم^۱ و حفظ حریم شخصی^۲ و همچنین ظهور دستگاه‌هایی مانند پهباد ها و خودروهای خودران که این مسئله در آن‌ها اهمیت زیادی دارد، استفاده از پردازش ابری^۳ را در این موارد نا ممکن کرده است. در همین سو تحقیقات در زمینه محاسبات در لبه^۴ بسیار محبوب شده است تا آموزش و یادگیری بدون ارسال داده‌ها به صورت مستقیم، به یک سرور مرکزی انجام پذیرد. این موضوع، یک زمینه نوپا در یادگیری ماشین به یادگیری فدرال^۵ را مطرح می‌کند که منجر به صرفه جویی در استفاده از انرژی، پهنای باند و حافظه می‌شود و نیازمند به قدرت پردازشی کمتری است. برای تجمیع^۶ پارامتر های محاسبه شده مدل محلی^۷ در سرور نهایی از الگوریتم میانگین گیری فدرال استفاده می‌شود که در آن، از میان پارامترهای متفاوت مدل به صورت وزن دار میانگین گرفته خواهد شد و مدل کلی^۸ را تشکیل می‌دهد. با این حال، پهنای باند ارتباطی محدود، مهم‌ترین محدودیت برای تجمیع به‌روزرسانی‌های محاسباتی محلی است. در این مقاله روش محاسباتی مبتنی بر محاسبه بی سیم^۹ معرفی می‌شود تا برای تجمیع سریع مدل جهانی که از ویژگی تجمیع همزمان کانال چندرسانه‌ای بی سیم در آن بکار گرفته می‌شود را استفاده کنیم. دستیابی به این مهم نیازمند به انتخاب مطلوب دستگاه‌های محلی و شکل دهی^{۱۰} مناسب سیگنال می‌باشد. این مسئله می‌تواند به صورت یک مسئله بهینه سازی تنک^{۱۱} و رنک پایین مدل شود. برای حل این مسئله ما یک توصیف به صورت (DC) difference-of-convex-functions برای مسئله بهینه سازی ارائه می‌دهیم تا حل آن امکان پذیر شود و سپس به کمک الگوریتم DC که در ادامه بیان می‌کنیم به حل آن می‌پردازیم.

low-latency^۱
 privacy^۲
 cloud computing^۳
 edge computing^۴
 federated learning^۵
 aggregation^۶
 local^۷
 global^۸
 over-the-air computation^۹
 beamforming^{۱۰}
 sparse^{۱۱}

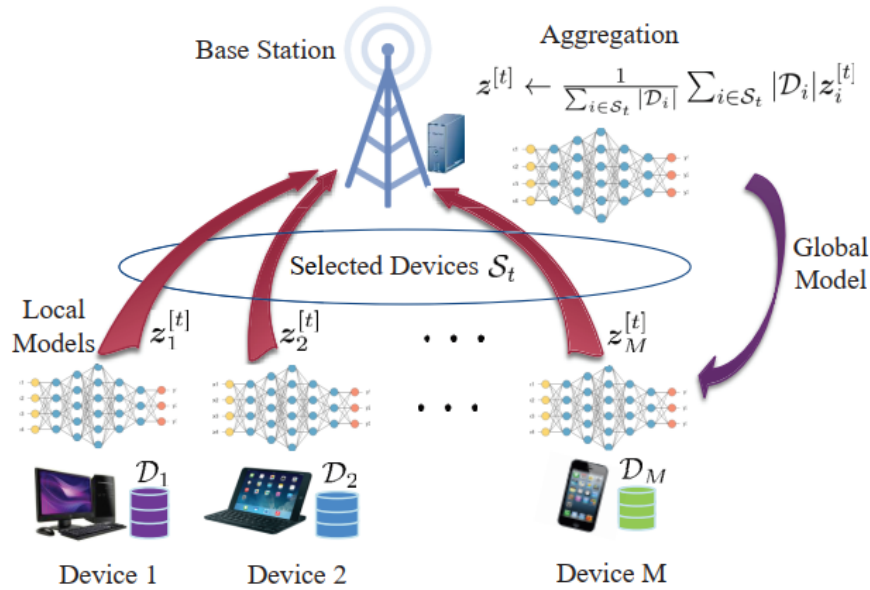
١ مقدمة

با افزایش روزافزون میزان داده های در دسترس و رشد الگوریتم های یادگیری ماشین، نیاز به قدرت پردازشی بالا برای این اعمال بیش از هر زمان دیگری حس می شود. یک روش متداول، استفاده از پردازش ابری می باشد. این روش نیاز به یک سرور مرکزی و فضای بالای ذخیره سازی و انتقال همه داده می باشد. از طرفی با گسترش پهباد ها و نیاز به انتقال با تاخیر بسیار کم و حفظ حریم شخصی نیاز به روش های جدیدی را برای پردازش الگوریتم های یادگیری ماشین ایجاد می کند. یک روش جدید پیشنهاد شده یادگیری ماشین در لبه ۱۲ می باشد که در آن به جای پردازش مرکزی و فرستادن تمام اطلاعات به سرور، داده ها را به صورت محلی آموزش دهیم. محدودیت اصلی در این زمینه پهنای باند، انرژی و توان پردازشی محدود در لبه می باشد. در سال ها اخیر تحقیقات بالایی برای بهبود انجام محاسبات لبه به کمک طراحی مناسب سخت افزار- نرم افزار صورت گرفته. که یک روش تازه توسعه یافته به نام یادگیری فدرال به بررسی یادگیری مستقیم در لبه می پردازد تا به صورت بهینه تری از پهنای باند استفاده کرده و حفظ حریم شخصی را بهبود دهد. این روش در جایی که ارسال اطلاعات به سرور مرکزی مطلوب نباشد مورد استفاده است. با این وجود در استفاده از یادگیری فدرال چالش هایی دارد که به آن می پردازیم:

۱. داده های جمع آوری شده که i.i.d نیستند مدل سازی و فیت کردن توزیع بر روی داده های جمع آوری شده را دشوار می کنند.
۲. لود بالای داده های مخابراتی ارسال شده در مقیاس یادگیری فدرال می تواند بهینه بودن سیستم را دچار مشکل کند.
۳. برخی از دستگاه هایی که دارای تاخیر بالا در محاسبات هستند می توانند عملکرد سیستم را بسیار کند کنند.
۴. رفتار خصمانه دستگاه ها می تواند موجب نشتی اطلاعات و نقض حریم شخصی شود.
۵. برخی اشکالات در پیاده سازی سیستم مانند سرعت همگرایی، اتصال و ... در مقایسه با یادگیری مرکزی.

این مقاله به بهبود کارایی مخابراتی و سریع تر کردن میانگین گیری (الگوریتم FedAvg) در یادگیری فدرال می پردازد. در این مقاله پیشنهاد می شود که محاسباتی مبتنی بر محاسبه بی سیم برای کم کردن بار مخابراتی و افزایش کارایی استفاده شود. این روش با استفاده از خاصیت superposition کانال چند مسیره بی سیم، میانگین وزنی از بروزرسانی های محلی را از طریق انتقال همزمان محاسبه می کند. رویکرد پیشنهادی شامل انتخاب همزمان دستگاه ها و طراحی شکل دهی سیگنال گیرنده است تا تعداد حداکثر دستگاه های مورد نیاز را برای رسیدن به مقدار مشخصی خطای حداقل مربعات 10^{-3} محاسبه کند. انتخاب دستگاه های بیشتر موجب بهبود سرعت همگرایی می شود اما می تواند خطای تجمع را افزایش دهد. این یک داد و ستد 10^{-4} موجود در این مسئله بهینه سازی می باشد که برای حل مسئله بهینه سازی بکار می رود. این مسئله بهینه سازی به صورت nonconvex quadratic constraints مدل می شود. که در ادامه با جزئیات بیشتری به آن می پردازیم. با این حال، این مسئله به لحاظ محاسباتی پیچیده است و ما رویکردی با مدل سازی کم رتبه 10^{-5} و خاصیت تنگ ارائه می دهیم و آن را به صورت قید های nonconvex quadratic همراه قید اضافه، رنک ۱ و استفاده از تکنیک matrix lifting ارائه می دهیم. برای حل این مسئله بهینه سازی از راه difference-of-convex-functions (DC) استفاده می کنیم و نشان می

edge ML¹²mean squared error¹³trade off¹⁴low-rank¹⁵



شکل ۱: یادگیری فدرال در دستگاه

در اینجا، $D = (x_j, y_j) : j = 1, \dots, T$ مجموعه داده‌های موجود در فرایند آموزش را نشان می‌دهد. مجموعه داده محلی در دستگاه i با نماد $D_i \subseteq D$ نشان داده می‌شود. پهنای باند محدود شبکه مهم ترین گره ۲۰ برای تجمیع مدل جهانی در یادگیری فدرال است. برای کم کردن تعداد دور های مخابراتی برای تجمیع مدل نهایی در یادگیری فدرال، الگوریتم میانگین گیری (FedAvg) پیشنهاد شده که به طور خاص در دور t ام:

۱. BS یک زیر مجموعه ای از دستگاه های موبایل $S_t \subseteq \{1, \dots, M\}$ را انتخاب می کند.

۲. BS مدل جهانی به روزرسانی شده $z^{[t-1]}$ را به دستگاه مشخص S_t می فرستد.

۳. هر دستگاه انتخاب شده $i \in S_t$ الگوریتم به روزرسانی محلی (برای مثال گرادیان تصادفی کاهشی ^{۲۱}) را بر اساس داده محلی D_i و مدل جهانی $z^{[t-1]}$ اجرا می کند و خروجی آن مدل محلی به روزرسانی شده $z_i^{[t]}$ است.

۴. BS تمام به روزرسانی های محلی $z_i^{[t]}$ را با $i \in S_t$ را تجمیع می کند، به عبارتی مدل جهانی به روزرسانی شده $z^{[t]}$ را به دست می آورد.

چارچوب میانگین گیری توزیع شده در الگوریتم ۱ نشان داده شده است.

در این مقاله، هدف ما ارتقای کارایی مخابراتی در یادگیری فدرال تحت دستگاه با توسعه رویکردی سریع برای تجمیع سریع مدل برای به روزرسانی های محاسبه شده محلی در الگوریتم FedAvg است. یک

^{۲۰}bottleneck
^{۲۱}stochastic gradient algorithm

Algorithm 1: Federated Averaging (FedAvg) Algorithm-

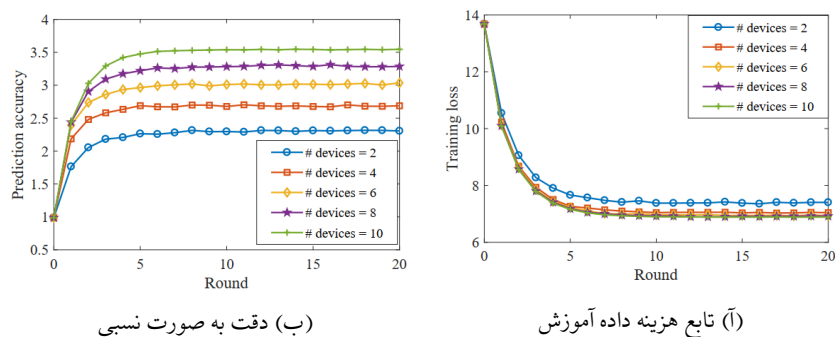
```

m
BS executes:
initialize  $w_0$ .
for each round  $t = 1, 2, \dots$  do
     $\mathcal{S}_t \leftarrow$  select a subset of  $M$  devices;
    broadcast global model  $z^{[t-1]}$  to devices in  $\mathcal{S}_t$ .
    for each mobile device  $i \in \mathcal{S}_t$  in parallel do
         $z_i^{[t]} \leftarrow \text{LocalUpdate}(\mathcal{D}_i, z^{[t-1]})$ 
    end
     $z^{[t]} \leftarrow \frac{1}{\sum_{i \in \mathcal{S}_t} |\mathcal{D}_i|} \sum_{i \in \mathcal{S}_t} |\mathcal{D}_i| z_i^{[t]}$  (aggregation)
end

```

شکل ۲: الگوریتم میانگین گیری فدرال

مشاهده کلیدی برای الگوریتم FedAvg این است که عملکرد یادگیری آماری می تواند با انتخاب بیشترین تعداد کارگر^{۲۲} در هر دور بهبود یابد. در شکل ۲ یک مثال با استفاده از الگوریتم FedAvg بر روی یک دسته بند SVM روی داده ۱۰-CIFAR آموزش داده شده است را نشان می دهد.



شکل ۳: تابع هزینه و دقت با استفاده از الگوریتم FedAvg بر روی یک دسته بند SVM روی داده آموزش CIFAR-۱۰

توجه کنید که روش تجميع مدل نیاز به محاسبه میانگین وزن دار به روزرسانی های محاسبه شده محلی و ارتباط از دستگاه های موبایل انتخاب شده به BS دارد. بنابراین، در این مقاله ما یک رویکرد نوین برای طراحی همزمان مخابراتی و محاسبه برای تجميع سریع مدل توسعه می دهیم. رویکرد ما بر اصول محاسبه

بی سیم و استفاده از خاصیت superposition سیگنال در کانال چند مسیره بی سیم است. مزیت استفاده از این روش را به صورت خلاصه در زیر می توان بیان کرد.

- ماکسیمم کردن تعداد دستگاه های هر دور برای سریع تر کردن سرعت همگرایی در فرآیند یادگیری توزیع شده در فرآیند آموزش.
- کمینه کردن خطای تجمیع مدل برای بهتر کردن دقت مدل در عملکرد سیستم در فرآیند استنباط

۲.۲ محاسبات بی سیم برای تجمیع

اخیرا روش محاسبه بی سیم یک رویکرد برای تجمیع سریع داده های بی سیم از طریق محاسبه یک تابع نمایش دهنده ^{۲۳} داده (مانند میانگین) از داده های توزیع شده که از چند فرستنده دریافت شده، رایج شده است. با یکپارچه کردن محاسبات و مخابرات با استفاده از خاصیت superposition سیگنال در کانال چند مسیره بی سیم، محاسبه بی سیم می تواند با انتقال همزمان، محاسبه تابع هدف را انجام دهد و در نتیجه کارایی ارتباطی را نسبت به انتقال متعامد به طور قابل ملاحظه ای بهبود بخشد. مشاهده کلیدی در الگوریتم FedAvg این است که مدل جهانی از طریق محاسبه میانگین وزن دار به روزرسانی های محاسبه شده به صورت محلی در هر دستگاه انتخاب شده به روزرسانی می شود، که در دسته بندی محاسبه تابع نمایش دهنده از داده های توزیع شده قرار می گیرد. در این مقاله، رویکرد محاسبه بی سیم را برای تجمیع کارآمد ارتباطی در سیستم یادگیری فدرال ارائه خواهیم داد. بردار هدف که برای تجمیع به روزرسانی مدل های محلی به کار می رود به صورت زیر ارائه می شود.

$$z = \psi \left(\sum_{i \in \mathcal{S}} \phi_i(z_i) \right)$$

که در آن z_i مدل به روزرسانی شده i ام، $\phi_i = |\mathcal{D}_i|$ متغیر اسکالر پیش پردازش در دستگاه i ، $\psi = \frac{1}{\sum_{k \in \mathcal{S}} |\mathcal{D}_k|}$ متغیر اسکالر پس از پردازش در BS و \mathcal{S} مجموعه دستگاه های انتخاب شده است. سمبل هر بردار قبل از پردازش به صورت $s_i := z_i \in \mathbb{C}^d$ بیان می شود که به صورت نرمالایز با واریانس ۱ است. به بیان دیگر $\mathbb{E}(ss^H) = \mathbf{I}$. در هر بازه زمان j ، $j \in \{1, \dots, d\}$ ، هر دستگاه سیگنال $s_i^{(j)} \in \mathbb{C}$ را به BS می فرستد. ما تابع هدف

$$g^{(j)} = \sum_{i \in \mathcal{S}} \phi_i(s_i^{(j)})$$

را به صورتی تعریف می کنیم که از طریق محاسبات بی سیم در بازه زمانی j ام تخمین زده شود. برای ساده سازی نوشتاری ما اندیس j را برداشته و سیگنال دریافتی در BS را به صورت زیر می نویسیم.

$$y = \sum_{i \in \mathcal{S}} h_i b_i s_i + n$$

که در آن $b_i \in \mathbb{C}$ اسکالر ارسال شده، $h_i \in \mathbb{C}^N$ بردار کانال بین دستگاه i ام و BS و $n \sim \mathcal{CN}(0, \sigma^2 \mathbf{I})$ بردار نویز می باشد. توان ارسالی در دستگاه i به صورت زیر داده می شود.

$$\mathbb{E}(|b_i s_i|^2) = |b_i|^2 \leq P_0$$

که در آن $P_0 > 0$ که بیشترین مقدار توان ارسالی است. مقدار تخمین زده شده قبل از ارسال پس-پردازش در BS به صورت زیر داده می شود.

$$\hat{g} = \frac{1}{\sqrt{\eta}} \mathbf{m}^H \mathbf{y} = \frac{1}{\sqrt{\eta}} \mathbf{m}^H \sum_{i \in S} \mathbf{h}_i b_i s_i + \frac{\mathbf{m}^H \mathbf{n}}{\sqrt{\eta}}$$

که در آن $\mathbf{m} \in \mathbb{C}^N$ بردار شکل دهی سیگنال دریافتی و η پارامتر نرمالیزه است. بنابراین هر عنصر بردار هدف می تواند به صورت $\hat{z} = \psi(\hat{g})$ در BS نمایش داده شود.

پرفورمنس روش محاسبات بی سیم را به کمک الگوریتم FedAvg در تجمیع را با خطای میانگین مربعات به صورت زیر می توان بیان کرد.

$$\text{MSE}(\hat{g}, g) = \mathbb{E}(|\hat{g} - g|^2) = \sum_{i \in S} \left| \frac{\mathbf{m}^H \mathbf{h}_i b_i}{\sqrt{\eta}} - \phi_i \right|^2 + \sigma^2 \frac{\|\mathbf{m}\|^2}{\eta}.$$

می توان گفت که با داشتن فرم دهی دلخواه سیگنال به صورت \mathbf{m} در گیرنده انتخاب شده با انتخاب زیر کمترین مقدار خطا با فرستنده zero-forcing خواهیم داشت:

$$b_i = \sqrt{\eta} \phi_i \frac{(\mathbf{m}^H \mathbf{h}_i)^H}{\|\mathbf{m}^H \mathbf{h}_i\|^2}$$

بنابراین برای پارامتر نرمالیزه نیز داریم:

$$\eta = \min_{i \in S} \frac{P_0 \|\mathbf{m}^H \mathbf{h}_i\|^2}{\phi_i^2}$$

که بر این اساس خطای MSE را می توان به صورت زیر بازنویسی کرد.

$$\text{MSE}(\hat{g}, g; \mathcal{S}, \mathbf{m}) = \frac{\|\mathbf{m}\|^2 \sigma^2}{\eta} = \frac{\sigma^2}{P_0} \max_{i \in S} \phi_i^2 \frac{\|\mathbf{m}\|^2}{\|\mathbf{m}^H \mathbf{h}_i\|^2}$$

توجه شود که ما از یک بردار شکل دهی بجای M بردار استفاده کردیم اما می توان اثبات کرد اگر از M بردار نیز استفاده کنیم به رابطه یکسانی خواهیم رسید.

۳.۲ فرمول بندی مسئله

همانطور که گفته شد برای استفاده از بیشترین تعداد دستگاه ها به صورتی کمترین خطا را در محاسبات بی سیم داشتیم مسئله بهینه سازی زیر را ارائه می دهیم.

$$\text{maximize}_{\mathcal{S}, \mathbf{m} \in \mathbb{C}^N} |\mathcal{S}| \quad \text{to subject} \quad \left(\max_{i \in \mathcal{S}} \phi_i^2 \frac{\|\mathbf{m}\|^2}{\|\mathbf{m}^H \mathbf{h}_i\|^2} \right) \leq \gamma$$

که در آن $\gamma > 0$ خطای MSE است و \mathcal{S} اندازه مجموعه S که دستگاه های انتخاب شده برای به روزرسانی مدل می باشد. متأسفانه، این مسئله بهینه سازی ترکیبی مختلط به دلیل تابع هدف ترکیبی \mathcal{S} و محدودیت غیرخطی MSE با متغیر ترکیبی مشترک \mathcal{S} و متغیر پیوسته \mathbf{m} بسیار پیچیده است. با توجه

به این مشاهده، ما نشان خواهیم داد که این مسئله می‌تواند با بهینه‌سازی تعداد محدودیت‌های غیرخطی ممکن حل شود. به طور خاص، برای طراحی الگوریتم‌های کارآمد، ما رویکرد نمایش تنک را برای یافتن بیشینه تعداد دستگاه‌های مرتبط ارائه خواهیم داد، سپس محدودیت‌های غیرخطی quadratic را با استفاده از تکنیک بالابری ماتریس^{۲۴} به محدودیت‌های affine با یک محدودیت رتبه یک تبدیل خواهیم کرد. توجه کنید در این بررسی CSI کامل در فرستنده و گیرنده وجود دارد. برای صرفه جویی در ارسال بازخورد^{۲۵} مقدار اسکالر b_i برای هر دستگاه i فرستاده می‌شود. همچنین بررسی‌های بیشتر برای کانال بازخورد را می‌توان در دیگر منابع به صورت کامل بررسی کرد.

۳ بهینه‌سازی تنک و کم‌رتبه برای یادگیری فدرال توزیع شده در دستگاه

در این بخش ما یک مدل تنک و کم‌رتبه بهینه سازی برای یادگیری توزیع شده فدرال در دستگاه ارائه می‌دهیم که انتخاب دستگاه در آن اهمیت دارد.

۱.۳ بهینه‌سازی تنک و کم‌رتبه

مسئله بهینه سازی بخش قبل را به صورت زیر می‌توان بازنویسی کرد:

$$\begin{aligned} & \underset{S, \mathbf{m} \in \mathbb{C}^N}{\text{maximize}} |\mathcal{S}| \\ & \text{to subject } \|\mathbf{m}\|^2 - \gamma_i \|\mathbf{m}^H \mathbf{h}_i\|^2 \leq 0, i \in \mathcal{S}, \\ & \|\mathbf{m}\|^2 \geq 1, \end{aligned}$$

که در آن $\gamma_i = \frac{\gamma}{\phi_i^2}$. بنابراین هدف ما بیشترین کردن تعداد ممکن قیدهای MSE $\|\mathbf{m}\|^2 - \gamma_i \|\mathbf{m}^H \mathbf{h}_i\|^2 \leq 0$ با شرط $\|\mathbf{m}\|^2 \geq 1$ که از جزئیات اثبات آن صرف نظر می‌شود.

برای بیشترین کردن تعداد قیدهای ممکن در مسئله قبل، می‌توان تعداد x_k های غیر صفر را کمینه کرد. به عبارتی:

$$\begin{aligned} & \underset{\mathbf{x} \in \mathbb{R}_+^M, \mathbf{m} \in \mathbb{C}^N}{\text{minimize}} \|\mathbf{x}\|_0 \\ & \text{to subject } \|\mathbf{m}\|^2 - \gamma_i \|\mathbf{m}^H \mathbf{h}_i\|^2 \leq x_i, \forall i \\ & \|\mathbf{m}\|^2 \geq 1 \end{aligned}$$

تنک بودن ساختار \mathbf{x} دلالت بر دسترسی هر دستگاه موبایل دارد. اگر $x_i = 0$ ، دستگاه i ام می‌تواند انتخاب شود که شرط MSE را برآورده کند. هرچند قید MSE و $\|\mathbf{m}\|^2 \geq 1$ عبارت‌های nonconvex quadratic هستند و برای پرداختن به آنها باید از تکنیک بالابری ماتریس استفاده کرد. به طور به خصوص با بالا بردن ماتریس \mathbf{m} به صورت یک ماتریس رتبه یک و مثبت نیمه معین^{۲۶} $\mathbf{M} = \mathbf{m}\mathbf{m}^H$ مسئله قبل

^{۲۴}lifting matrix
^{۲۵}feedback
^{۲۶}positive semidefinite(PSD)

را به صورت زیر می توان بازنویسی کرد.

$$\begin{aligned} \mathcal{P} : \quad & \underset{\mathbf{x} \in \mathbb{R}_+^M, \mathbf{M} \in \mathbb{C}^{N \times N}}{\text{minimize}} \quad \|\mathbf{x}\|_0 \\ & \text{to subject} \quad \text{Tr}(\mathbf{M}) - \gamma_i \mathbf{h}_i^H \mathbf{M} \mathbf{h}_i \leq x_i, \forall i, \\ & \quad \mathbf{M} \succeq \mathbf{0}, \text{Tr}(\mathbf{M}) \geq 1, \\ & \quad \text{rank}(\mathbf{M}) = 1. \end{aligned}$$

هر چند مسئله \mathcal{P} محدب نیست اما در ادامه الگوریتم مناسب برای حل آن را ارائه می دهیم.

۲.۳ آنالیز مسئله

مسئله \mathcal{P} که یک مسئله غیر محدب با قید های تنک و رنک پایین است علاوه بر مخابرات وایرلس در ادبیات یادگیری ماشین، پردازش سیگنال و آمار ابعاد بالا نیز دیده می شود. برخی الگوریتم های توسعه یافته برای حل این مسئله عبارتند از:

۱. بهینه سازی تنک: $l_1 - norm$ به صورت طبیعی یک تابع محدب می باشد و می توان برای تابع تنک غیر محدب از آن استفاده کرد و نتیجه نهایی یک مسئله آشنا در ادبیات بهینه سازی می شود.
 ۲. بهینه سازی کم رتبه: به صورت ساده با حذف قید رنک ۱ در مسئله \mathcal{P} و استفاده از تکنیک SDR^{۲۷} برای حل آن. این روش به صورت گسترده استفاده می شود اما ممکن است پاسخ نهایی رتبه ۱ نباشد که می توان از تقریب رتبه ۱ برای آن با استفاده از متغیر های گوسی استفاده کرد. هر چند با افزایش تعداد آنتن ها N عملکرد سیستم دچار مشکل می شود و احتمال رتبه ۱ بودن جواب کاهش می یابد.
- برای غلبه بر محدودیت های موجود ما الگوریتم DC را معرفی می کنیم که از روش های روز بسیار بهتر بوده و آن ها را ارتقا می دهد. به صورت به خصوص:
- روش DC را به صورت پارامتر آزاد توسعه می دهیم که تنک بودن را گسترش داده و بیشترین تعداد دستگاه را انتخاب کنیم.
 - به جای حذف قید رتبه ۱ به صورت مستقیم، یک الگوریتم جدید DC پیشنهاد می دهیم تا رتبه ۱ بودن پاسخ را تضمین کند.

۴ نمایش DC برای تابع های تنک و کم رتبه

در این بخش، یک چارچوب DC یکپارچه برای مسئله \mathcal{P} در یادگیری فدرال پیشنهاد می دهیم. به صورت خاص یک نمایش جدید DC برای $l_0 - norm$ تا تنک بودن را برای انتخاب دستگاه ایجاد کند. نمایش جدید DC برای تابع رنک به کار می رود تا به پاسخ های رنک ۱ منجر شود و به صورت دقیقی جواب پذیر بودن مسئله انتخاب دستگاه را نشان دهد.

^{۲۷} semidefinite relaxation

۱.۴ نمایش DC برای تابع تنک

در ابتدا Ky Fan k -norm را به صورت زیر تعریف می کنیم:

$$\|x\|_k = \sum_{i=1}^k |x_{\pi(i)}|$$

که در آن π جایگشتی از $\{1, 2, \dots, M\}$ می باشد که $x_{\pi(1)} \geq \dots \geq x_{\pi(M)}$ در واقع این نرم جمع بزرگترین k تای x است. اگر l_0 - norm بزرگتر از k نباشد، l_1 - norm آن برابر با Ky Fan k -norm می شود. پس بنابراین l_0 - norm را می توان نوشت:

$$\|x\|_0 = \min\{k : \|x\|_1 - \|x\|_k = 0, 0 \leq k \leq M\}$$

۲.۴ نمایش DC برای قید کم رتبه

برای یک ماتریس PSD $M \in \mathbb{C}^{N \times N}$ قید رتک ۱ به صورت معادل می توان به شکل زیر نوشته شود.

$$\sigma_i(M) = 0, \forall i = 2, \dots, N$$

که در آن $\sigma_i(M)$ برابر i مین مقدار بزرگ تکین^{۲۸} برای ماتریس M می باشد. همچنین توجه کنید که:


$$Tr(M) = \sum_{i=1}^N \sigma_i(M) \quad \|M\|^2 = \sigma_1(M)$$

پس برای ماتریس PSD M که $Tr(M) \geq 1$ می توان نوشت:

$$rank(M) = 1 \Leftrightarrow Tr(M) - \|M\|_2 = 0$$

۳.۴ نمایش یکپارچه DC

ایده اصلی نمایش یکپارچه DC پیشنهاد شده این است که در مرحله اول از خاصیت تنک بودن x استفاده شود که در این صورت به الویت انتخاب دستگاه ها کمک می کند. سپس باید یک مجموعه از پاسخ های ممکن را حل کنیم تا بیشترین مقدار دستگاه های انتخاب شده برای اینکه شرط MSE را ایجاب کنند را انتخاب کنیم. به صورت کلی این ساختاری دو مرحله ای را در شکل ۴ می توان مشاهده کرد.



شکل ۴: ساختار ۲ مرحله ای برای انتخاب دستگاه

^{۲۸}singular

جزئیات این ساختار دو مرحله ای به صورت زیر است:

۱. مرحله اول *Sparsity Inducing*: در مرحله اول برنامه DC زیر را برای مسئله \mathcal{P} حل می کنیم.

$$\begin{aligned} \mathcal{P}_{S1} : & \underset{\mathbf{x}, \mathbf{M}}{\text{minimize}} \|\mathbf{x}\|_1 - \|\mathbf{x}\|_k + \text{Tr}(\mathbf{M}) - \|\mathbf{M}\|_2 \\ & \text{to subject } \text{Tr}(\mathbf{M}) - \gamma_i \mathbf{h}_i^H \mathbf{M} \mathbf{h}_i \leq x_i, \forall i = 1, \dots, M \\ & \mathbf{M} \succeq \mathbf{0}, \quad \text{Tr}(\mathbf{M}) \geq 1, \mathbf{x} \succeq \mathbf{0}. \end{aligned}$$

با حل دنباله ای مسئله \mathcal{P}_{S1} ما می توانیم بردار تنک \mathbf{x}^* بدست آوریم به صورتی که مقدار هدف، با افزایش k از 0 تا M به 0 برسد. توجه کنید که قید رتبه ۱ بودن ماتریس \mathbf{M} هنگامی که مقدار هدف برابر 0 است با 0 برابر است مطابق $\text{Tr}(\mathbf{M}) - \|\mathbf{M}\|_2 = 0$

۲. مرحله دوم *Feasibility Detection*: پاسخ یافت شده \mathbf{x} در مرحله قبل را شکاف بین مقدار مورد نیاز MSE و MSE قابل دستیابی برای هر دستگاه را توصیف می کند. بنابراین در مرحله دوم، پیشنهاد می شود اگر x_k مقدار کوچکی بود، دستگاه k را با اولویت بیشتری انتخاب می کنیم. عناصر \mathbf{x} را می توان به صورت نزولی با ترتیب $x_{\pi(1)} \geq \dots \geq x_{\pi(M)}$ نوشت. ما کمترین مقدار k را با افزایش این مقدار از 1 تا M به صورتی که امکان انتخاب تمامی دستگاه ها در $S^{[k]}$ ممکن باشد که در آن مجموعه $S^{[k]}$ به صورت $\{\pi(k), \pi(k+1), \dots, \pi(M)\}$ انتخاب می شود. با جزئیات بیشتر، اگر تمام دستگاه های $S^{[k]}$ بتوانند انتخاب شوند مسئله بهینه سازی

$$\begin{aligned} & \text{find } \mathbf{m} \\ & \text{to subject } \|\mathbf{m}\|^2 - \gamma_i \|\mathbf{m}^H \mathbf{h}_i\|^2 \leq 0, \forall i \in S^{[k]} \\ & \|\mathbf{m}\|^2 \geq 1 \end{aligned}$$

قابل حل شده و با استفاده از روش بالا بردن ماتریس به صورت معادل به شکل زیر قابل نوشتن است.

$$\begin{aligned} & \text{find } \mathbf{M} \\ & \text{to subject } \text{Tr}(\mathbf{M}) - \gamma_i \mathbf{h}_i^H \mathbf{M} \mathbf{h}_i \leq 0, \forall i \in S^{[k]} \\ & \mathbf{M} \succeq \mathbf{0}, \text{Tr}(\mathbf{M}) \geq 1, \text{rank}(\mathbf{M}) = 1 \end{aligned}$$

برای تضمین کردن ممکن بودن قید رتبه ثابت تا به توان به صورت دقیق قید MSE را ممکن کرد ما روش DC زیر را با کمینه کردن اختلاف بین اثر ماتریس و نرم ۲ ماتریس پیشنهاد می دهیم:

$$\begin{aligned} \mathcal{P}_{S2} : & \underset{\mathbf{M}}{\text{minimize}} \text{Tr}(\mathbf{M}) - \|\mathbf{M}\|_2 \\ & \text{to subject } \text{Tr}(\mathbf{M}) - \gamma_i \mathbf{h}_i^H \mathbf{M} \mathbf{h}_i \leq 0, \forall i \in S^{[k]} \\ & \mathbf{M} \succeq \mathbf{0}, \quad \text{Tr}(\mathbf{M}) \geq 1. \end{aligned}$$

به عبارت دیگر، وقتی که مقدار هدف تابع \mathcal{P}_{S2} با مجموعه داده شده $S^{[k]}$ برابر 0 می شود، می توان نتیجه گرفت که تمام دستگاه های در $S^{[k]}$ شرط MSE را برآورده می کنند و به عبارت دیگر مسئله گفته شده در ابتدای این بخش برای آن قابل حل است. توجه کنید که پاسخ \mathbf{M}^* باید یک ماتریس با رتبه دقیقاً ۱ باشد و بردار شکل دهی گیرنده از طریق تجزیه کولسکی^{۲۹} به صورت $\mathbf{M}^* = \mathbf{m} \mathbf{m}^H$ قابل دستیابی است.

چارچوب پیشنهادی DC برای حل مسئله بهینه سازی تنک و کم رتبه یادگیری فدرال به صورت خلاصه در الگوریتم ۲ ارائه شده است.

^{۲۹}decomposition Cholesky

Algorithm 2: DC Representation Framework for Solving Problem \mathcal{P} in Federated Learning with Device Selection

Step 1: sparsity inducing

$k \leftarrow 0$

while objective value of \mathcal{P}_{S1} is not zero **do**

 Obtain solution \mathbf{x} by solving the DC program

\mathcal{P}_{S1}

$k \leftarrow k + 1$

end

Step 2: feasibility detection

Order \mathbf{x} in descending order as $x_{\pi(1)} \geq \dots \geq x_{\pi(M)}$

$k \leftarrow 1$

while objective value of \mathcal{P}_{S2} is not zero **do**

$\mathcal{S}^{[k]} \leftarrow \{\pi(k), \pi(k+1), \dots, \pi(M)\}$

 Obtain solution \mathbf{M} by solving the DC program

\mathcal{P}_{S2}

$k \leftarrow k + 1$

end

Output: \mathbf{m} through Cholesky decomposition

$\mathbf{M} = \mathbf{m}\mathbf{m}^H$, and the set of selected devices

$\mathcal{S}^{[k]} = \{\pi(k), \pi(k+1), \dots, \pi(M)\}$

شکل ۵: الگوریتم DC ارائه شده برای حل مسئله بهینه سازی

۵ الگوریتم DC برای برنامه DC با تضمین همگرایی

در این بخش، الگوریتم DC با حل مسئله اصلی DC و دوگان \mathcal{S}^* مسئله DC که به صورت محدب تسهیل شده اند، توسعه می یابد. برای برقراری همگرایی به صورت قوی تر ما ترم های quadratic را به مسئله محدب اضافه می کنیم، به صورتی که اختلاف آن ها (مقدار هدف) یکسان باقی بماند. با این رویکرد، تابع هدف DC را به صورت اختلاف تابع های قویا محدب نمایش می دهیم که به موجب آن نرخ همگرایی الگوریتم DC را برقرار می کنیم.

۱.۵ نمایش به صورت اختلاف تابع های قویا محدب

فرمول بندی برنامه های \mathcal{P}_{S1} و \mathcal{P}_{S2} به صورت تنک و کم رتبه غیر محدب با قید های محدب هستند. با وجود غیر محدب بودن توابع DC، ساختار خوب آنها باعث می شود که الگوریتم DC بر اساس اصول ارائه شده بتواند توسعه یابد. به منظور برقراری نتیجه همگرایی الگوریتم DC، تابع هدف DC را به عنوان تفاضل توابع قویا محدب نشان می دهیم. به صورت خاص می توانیم مسئله \mathcal{P}_{S1} را به صورت زیر:

$$\underset{x, M}{\text{minimize}} f_1 = \|x\|_1 - \|x\|_k + \text{Tr}(M) - \|M\|_2 + I_{C_1}(x, M)$$

و مسئله \mathcal{P}_{S2} را به صورت زیر:

$$\underset{M}{\text{minimize}} f_2 = \text{Tr}(M) - \|M\|_2 + I_{C_2}(M)$$

بازنویسی کنیم که در آن C_1 و C_2 مخروطی شکل های نیمه-معین مثبت (به صورت معادل مجموعه ای که شامل تمام ماتریس های نیمه-معین مثبت) هستند که قیدهای مسئله \mathcal{P}_{S1} و مسئله \mathcal{P}_{S2} را ترکیب می کنند و تابع نشانگر^{۳۱} به صورت زیر تعریف شده است:

$$I_{C_1}(x, M) = \begin{cases} 0, & (x, M) \in C_1 \\ +\infty, & \text{otherwise} \end{cases}$$

برای نشان دادن همگرایی نتایج الگوریتم DC ما توابع f_1 و f_2 را به صورت اختلاف توابع قویا محدب به صورت $f_1 = g_1 - h_1$ و $f_2 = g_2 - h_2$ که در آن:

$$g_1 = \|x\|_1 + \text{Tr}(M) + I_{C_1}(x, M) + \frac{\alpha}{2} (\|x\|_F^2 + \|M\|_F^2),$$

$$h_1 = \|x\|_k + \|M\|_2 + \frac{\alpha}{2} (\|x\|_F^2 + \|M\|_F^2),$$

$$g_2 = \text{Tr}(M) + I_{C_2}(M) + \frac{\alpha}{2} \|M\|_F^2,$$

$$h_2 = \|M\|_2 + \frac{\alpha}{2} \|M\|_F^2.$$

با افزودن ترم های quadratic توابع g_1, g_2, h_1, h_2 همگی α -قویا محدب هستند. اکنون توابع f_i را به صورت زیر می توان نوشت:

$$\underset{X \in \mathbb{C}^{m \times n}}{\text{minimize}} f(X) = g(X) - h(X)$$

در حوزه مختلط X ، ما از محاسبات ویرتینگر^{۳۲} برای طراحی الگوریتم استفاده می کنیم. الگوریتم DC از طریق ساخت دنباله هایی از کاندیدهای حل های مسئله اصلی و حل های مسئله دوگان ارائه می شود. از آنجایی که مسئله اصلی و مسئله دوگانی آن هنوز غیرمحدب هستند، نیاز به تسهیل محدب است.

۲.۵ الگوریتم DC برای ماتریس های تنک و کم رتبه

بر اساس اصل فنچل^{۳۳} دوگان مسئله قبل به صورت زیر ارائه می شود.

$$\underset{Y \in \mathbb{C}^{m \times n}}{\text{minimize}} h^*(Y) - g^*(Y)$$

^{۳۱}indicator

^{۳۲}Wirtinger

^{۳۳}Fenchel

که در آن f^* و g^* مزدوج مختلط f و g هستند. تابع مزدوج به صورت زیر تعریف می شود:

$$g^*(Y) = \sup_{X \in \mathbb{C}^{m \times n}} X, Y - g(X)$$

که در آن $X, Y - g(X) = \text{Real}(\text{Tr}(X^H Y))$ ضرب داخلی دو ماتریس را بیان می کند. در دور t ام، الگوریتم DC ساده شده به حل تقریب محدب مسئله اصلی و مسئله دوگان با خطی کردن بخش مقعر می پردازد.

$$Y^{[t]} = \arg \inf_{Y \in \mathcal{Y}} h^*(Y) - \left[g^*(Y^{[t-1]}) + \langle Y - Y^{[t-1]}, X^{[t]} \rangle \right],$$

$$X^{[t+1]} = \arg \inf_{X \in \mathcal{X}} g(X) - \left[h(X^{[t]}) + \langle X - X^{[t]}, Y^{[t]} \rangle \right].$$

بر اساس Fenchel biconjugation theorem این مسئله قابل نوشتن به صورت زیر است.

$$Y^{[t]} = \partial_{X^{[t]}} h$$

که در آن $\partial_{X^{[t]}} h$ زیر گرادیان h نسبت به X در $X^{[t]}$ است. بنابراین $M^{[t]}$ و $x^{[t]}$ از الگوریتم DC برای مسئله \mathcal{P}_{S1} به عنوان پاسخ مسئله بهینه سازی محدب زیر ساخته می شود.

$$\begin{aligned} & \underset{x, M}{\text{minimize}} && g_1 - \langle \partial_{x^{[t-1]}} h_1, x \rangle - \langle \partial_{M^{[t-1]}} h_1, M \rangle \\ & \text{to subject} && \text{Tr}(M) - \gamma_i h_i^H M h_i \leq x_i, \forall i = 1, \dots, M \\ & && M \succeq 0, \quad \text{Tr}(M) \geq 1, x \succeq 0 \end{aligned}$$

همچنین $M^{[t]}$ برای مسئله \mathcal{P}_{S2} نیز به عنوان پاسخ مسئله بهینه سازی محدب زیر ساخته می شود.

$$\begin{aligned} & \underset{x, M}{\text{minimize}} && g_2 - \langle \partial_{M^{[t-1]}} h_2, M \rangle \\ & \text{to subject} && \text{Tr}(M) - \gamma_i h_i^H M h_i \leq 0, \forall i \in S^{[k]} \\ & && M \succeq 0, \quad \text{Tr}(M) \geq 1 \end{aligned}$$

زیر گرادیان h_1 و h_2 برابر است با:

$$\partial_x h_1 = \partial \|x\|_k + \alpha x, \quad \partial_M h_1 = \partial \|M\|_2 + \alpha M$$

که در آن زیر گرادیان $\|x\|_k$ به صورت زیر تعریف می شود.

$$i \text{ of entry } -\text{th} \partial \|x\|_k = \begin{cases} \text{sign}(x_i), & |x_i| \geq |x_{(k)}| \\ 0, & |x_i| < |x_{(k)}| \end{cases}.$$

زیر گرادیان $\|M\|_2$ می تواند به صورت $v_1 v_1^H$ که در آن $v_1 \in \mathbb{C}^N$ بردار ویژه بزرگترین مقدار ویژه $\sigma_1(M)$ است و می توان این موضوع را اثبات کرد.

۳.۵ هزینه محاسباتی و همگرایی

به صورت خلاصه می توان گفت هزینه محاسباتی در مرحله اول برای حل \mathcal{P}_{S1} برابر $O((N+M)^3)$ در هر مرتبه است و در مرحله بعدی برای حل \mathcal{P}_{S2} برابر $O(N^6)$ در هر مرتبه می باشد.

زوج مرتب $\{(M^{[t]}, x^{[t]})\}$ که در الگوریتم گفته شده برای حل \mathcal{P}_{S1} تولید می شود دارای خواص زیر است:

۱. هر نقطه محدود در دنباله $\{(M^{[t]}, x^{[t]})\}$ یک نقطه مهم برای f_1 با انتخاب یک نقطه شروع دلخواه است و دنباله $\{f_1^{[t]}\}$ به طور یکنوا کاهشی و همگرا است.

۲. به ازای هر $t = 0, 1, \dots$ داریم:

$$\text{Avg} \left(\|M^{[t]} - M^{[t+1]}\|_F^2 \right) \leq \frac{f_1^{[0]} - f_1^*}{\alpha(t+1)}$$

$$\text{Avg} \left(\|x^{[t]} - x^{[t+1]}\|_2^2 \right) \leq \frac{f_1^{[0]} - f_1^*}{\alpha(t+1)}$$

که f_1^* مینیمم جهانی f_1 و $\text{Avg} \left(\|M^{[t]} - M^{[t+1]}\|_F^2 \right)_{i=0}^t$ برابر میانگین $\{ \|M^{[t]} - M^{[t+1]}\|_F^2 \}_{i=0}^t$ است.

۳. این خواص به صورت مشابه برای حل مسئله \mathcal{P}_{S2} و تابع f_2 نیز برقرار است.


۶ نتایج شبیه سازی

در این بخش، آزمایش‌های عددی را برای مقایسه روش DC پیشنهادی با روش‌های روز در یادگیری فدرال انجام می‌دهیم. بردارهای ضریب کانال h_i بین BS و هر دستگاه موبایل از توزیع نرمال مختلط پیروی می‌کند به عبارت دیگر $h_i \sim \mathcal{CN}(0, \sigma^2 I)$. مقدار متوسط نسبت سیگنال به نویز^{۳۴} ارسالی $\frac{P_0}{\sigma^2}$ نیز برابر 20 dB انتخاب می‌شود. ما فرض می‌کنیم که تمام دستگاه‌ها تعداد یکسانی نقطه داده دارند به عبارت دیگر $|D_1| = \dots = |D_M|$ زوج پیش پردازش و پس پردازش به صورت $\phi_i = 1$ و $\psi = \frac{1}{|S|}$ انتخاب می‌شود.

۱.۶ تشخیص انجام پذیری


یک شبکه اینترنت اشیا^{۳۵} عادی با $M = 20$ دستگاه موبایل فعال برای یادگیری فدرال در نظر بگیرید. BS با $N = 6$ آنتن مجهز شده است. توجه کنید که احتمالاً تعداد زیادی دستگاه از طریق BS به اینترنت متصل هستند درحالی که به دلیل ترافیک نامنظم اینترنت، تعداد کمی از آن‌ها به صورت همزمان فعال هستند. این خاصیت ترافیک نامنظم دستگاه‌های IoT می‌تواند برای پشتیبانی از اتصال دستگاه‌های بزرگ به صورت همزمان با تشخیص همزمان دستگاه‌های فعال و تخمین ضرایب کانال بهره‌برداری کرد. عملکرد تشخیص قابلیت اجرا، به عبارتی بررسی قابلیت انتخاب دستگاه‌های انتخاب شده، یک مرحله مهم برای انتخاب دستگاه است. در ابتدا، رفتار همگرایی الگوریتم پیشنهادی DC برای تشخیص قابلیت انتخاب تمام دستگاه‌های موبایل، به عبارتی مسئله \mathcal{P}_{S2} با $S^{[k]} = \{1, \dots, 20\}$ ، ارزیابی می‌شود. نتایج برای $\gamma = 5$ dB و $\gamma = 3$ dB در شکل ۶ نشان داده شده است. این نتایج نشان می‌دهند که مقدار هدف برای $\gamma = 5$ dB به صفر می‌رسد اما برای $\gamma = 3$ dB نمی‌تواند به صفر برسد، که نشان می‌دهد الگوریتم پیشنهادی DC در صورت $\gamma = 5$ dB راه‌حل رتبه یک برمی‌گرداند اما در حالت دیگر نمی‌تواند.

^{۳۴}signal-to-noise-ratio
^{۳۵}(IoT) Things of Internet




شکل ۶: همگرایی الگوریتم DC پیشنهاد شده

می توانیم عملکرد تشخیص قابلیت اجرا توسط الگوریتم DC را با دیگر روش های موجود برای حل مسئله \mathcal{P}_{S2} بکار ببریم. روش SDR تنها قید رنک ۱ بودن را حذف کرده و روش بهینه سازی جهانی با پیچیدگی زمانی نمایی و تحمل خطای $\epsilon = 10^{-5}$ می باشد که در این شبیه سازی به کار رفته و نتیجه آن را در شکل ۷ می توان مشاهده کرد.



شکل ۷: احتمال امکان پذیری با الگوریتم های متفاوت


در این آزمایش، نتایج ۵۰۰ بار میانگین گرفته شده و نمایش داده شده اند. همانطور که مشخص است روش DC عملکرد بسیار بهتری دارد. در شکل ۸ نیز می توان عملکرد الگوریتم DC و الگوریتم های مشابه را با تغییر تعداد آنتن نشان داد. نتایج این بخش ۵۰۰ بار میانگین گرفته شده و نمایش داده شده اند. با افزایش تعداد آنتن ها در BS با قید MSE، سریع تر می توان به همگرایی رسید.



شکل ۸: احتمال امکان پذیری با الگوریتم DC پیشنهاد شده با تعداد آنتن های متفاوت

۲.۶ تعداد دستگاه های انتخاب با MSE مورد نظر

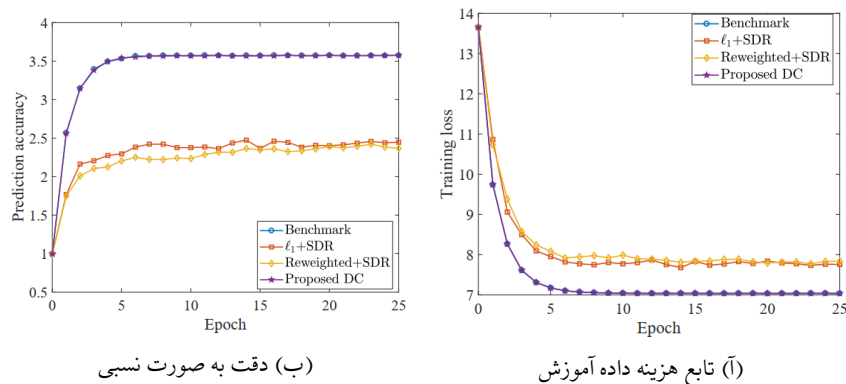
یک شبکه با ۲۰ دستگاه موبایل و یک BS با ۶ آنتن را در نظر بگیرید. با استفاده از چارچوب دو مرحله ای و قاعده ترتیب دهی در الگوریتم ۲، ما الگوریتم DC پیشنهادی را برای انتخاب دستگاه با روش های روز دیگر $l_1 + SDR$ و $Reweighted\ l_2 + SDR$ مقایسه می کنیم. نتایج با ۵۰۰ بار تکرار بازنمایی کانال مخابراتی با روش های متفاوت محاسبه شده و در شکل ۹ قابل مشاهده می باشد و می توان دید الگوریتم DC پیشنهادی می تواند بیشترین دستگاه ها را نسبت به روش های دیگر انتخاب کند.



شکل ۹: میانگین تعداد دستگاه های انتخاب شده با الگوریتم های متفاوت

۳.۶ عملکرد روش DC برای یادگیری فدرال گسترده

برای نشان دادن عملکرد رویکرد DC پیشنهادی برای انتخاب دستگاه در یادگیری توزیع شده فدرال، ما یک ماشین بردار پشتیبان را روی مجموعه داده CIFAR-۱۰ با یک BS شامل ۶ آنتن و ۲۰ دستگاه موبایل آموزش می‌دهیم. CIFAR-۱۰ یک مجموعه داده رایج از تصاویر برای طبقه‌بندی است که شامل ۱۰ کلاس مختلف اشیاء می‌باشد. برای مقایسه، مورد بنچمارک انتخاب همه دستگاه‌ها و جمع‌آوری همه به‌روزرسانی‌های محلی، بدون خطای تجمیع در نظر گرفته می‌شود. ما بر روی ۱۰ بازنمایی متفاوت کانال میانگین گیری می‌کنیم. عملکرد تمام الگوریتم‌ها با $\gamma = 5 \text{ dB}$ در شکل ۱۰ نشان داده شده است. در اینجا اندازه مجموعه آموزش و مجموعه آزمون را به ترتیب ۵۰۰۰ و ۱۰۰۰۰ انتخاب می‌کنیم.



شکل ۱۰: تابع هزینه و دقت برای یک دسته بند SVM روی داده CIFAR-۱۰ برای الگوریتم‌های گفته شده

نتایج شبیه‌سازی نشان می‌دهد که رویکرد DC پیشنهادی عملکرد بهتری با کمترین اتلاف آموزش و دقت پیش‌بینی بالاتری را داراست، همانطور که در شکل ۱۰ نشان داده شده است.

۷ نتیجه گیری

در این مقاله، ما یک رویکرد نوآورانه برای تجمیع سریع مدل کلی در یادگیری توزیعی فدرال بر اساس اصول محاسبات بی سیم ارائه دادیم. برای بهبود عملکرد یادگیری آماری در آموزش توزیع شده روی دستگاه، یک رویکرد نوآورانه برای مدل‌سازی تنک و کم‌رتبه‌ای ارائه دادیم تا تعداد بیشتری از دستگاه‌ها را با نیازمندی‌های MSE برای تجمیع مدل بیابیم. ما یک چارچوب یکپارچه نمایش DC ارائه دادیم تا تنک بودن و کم‌رتبه‌ای را به کار برده و توسط الگوریتم DC با تضمین همگرایی از طریق تسهیل محدب پشتیبانی شود. نتایج شبیه‌سازی عملکرد قابل تحسین رویکرد پیشنهادی را نسبت به الگوریتم‌های روز دنیا نشان می‌دهد.